

Podstawy kryptografii i bezpieczeństwa systemów informatycznych

Andrzej M. Borzyszkowski

Instytut Informatyki
Uniwersytet Gdański

sem. zimowy 2019/2020

inf.ug.edu.pl/~amb/

Integralność danych: MAC i funkcje skrótu

Integralność a prywatność

- Prywatność: Ewa nie potrafi odczytać wiadomości m z kryptogramu c
 - czy potrafi go zmienić złośliwie? (integralność)
- Szyfr strumieniowy
 - $c = m \oplus G(k)$, zmiana bitu w c zmienia ten sam bit w m
- Szyfr blokowy w trybach OFB oraz CTR
 - zasada szyfrowania jest podobna
 - zmiana bitu w c zmienia ten sam bit w m
- Szyfr blokowy w trybie ECB
 - zmiana bitu w c zmienia cały blok w wiadomości m
 - można bezkarnie zmienić kolejność bloków
- Szyfr blokowy w trybie CBC
 - zmiana bitu w IV zmienia bit w pierwszym bloku m
 - nagłówek pliku często ma ważne informacje

Integralność – definicja

- MAC (message authentication code)
 - algorytm generowania klucza k (np. losowy wybór)
 - algorytm obliczania $MAC(k, m)$ dla klucza k i wiadomości m
 - algorytm weryfikacji dla klucza k , wiadomości m oraz kodu uwierzytelniającego t
- Odporność na atak
 - wybrany jest pewien klucz k
 - Ewa ma dostęp do wyroczni obliczającej $MAC(k, _)$
 - Ewa wygrywa jeśli znajdzie prawidłowy skrót dla *jakiegokolwiek* nowej wiadomości
- Atak przez powtórzenie (Ewa kopiuje wiadomość ze skrótem)
 - nie jest objęty tą definicją
 - wymaga pojęcia stanu
 - np. uzgodniony zegar, albo licznik

Funkcja pseudolosowa jako MAC

- Dana funkcja pseudolosowa $F : [n] \times [n] \rightarrow [n]$
- $MAC(k, m) = F(k, m)$
 - weryfikacja: $t = MAC(k, m)$
- Twierdzenie: jest to bezpieczny algorytm uwierzytelniania dla ciągów ustalonej długości
 - dla funkcji losowej wartości $f(x)$ oraz $f(y)$ są niezależne,
 - funkcja pseudolosowa jest PPT nieodróżnialna od losowej
 - więc znajomość wielu wartości nie pomaga w znalezieniu nowej
- Problemem jest nadal funkcja $MAC : [n] \times [*] \rightarrow [*]$ dla ciągów dowolnej długości
 - a w praktyce będziemy żądać by $MAC : [n] \times [*] \rightarrow [\ell]$, stała długość

MAC dla ciągów dowolnej długości


- Pomysły nieprawidłowe:
- Obliczyć \oplus dla wszystkich bloków i wtedy MAC tej sumy
 - łatwo zmienić wiadomość zachowując sumę
- Obliczyć MAC dla każdego bloku osobno
 - można zmienić kolejność bloków
 - wiadomość można po prostu uciąć
 - można sklejać fragmenty różnych wiadomości
- Obliczyć MAC dla bloków numerowanych
 - nadal wiadomość można uciąć
 - nadal można sklejać fragmenty różnych wiadomości
- Obliczyć MAC dla bloków numerowanych i posiadających informację o łącznej długości
 - nadal można sklejać fragmenty różnych wiadomości zachowując długość

MAC dla ciągów dowolnej długości c.d.

- Rozwiązanie: każdy blok zawiera:
 - numer bloku (uniemożliwia przestawienie)
 - długość pliku (np. liczbę bloków, uniemożliwia ucięcie)
 - liczbę jednorazową (uniemożliwia sklejać wiadomości)
 - oraz fragment wiadomości
- MAC jest zestawem: liczba jednorazowa i ciąg MAC bloków

MAC dla ciągów dowolnej długości w trybie CBC

- Cel:
 - MAC powinien dawać wynik stałej długości
 - powinien stosować się do ciągów naprawdę długich
- MAC działa jak tryb blokowy CBC
 - ale tylko ostatni blok jest zwracany
 - wektor początkowy jest ustalony w definicji algorytmu
 - długość pliku też jest kodowana



- Wektor początkowy
 - dla szyfrowania jest niezbędny, zapewnia niedeterminizm
 - dla obliczania MAC jest szkodliwy, umożliwia zmianę pierwszego bloku wiadomości
- Zestaw wyników funkcji losowej
 - dla szyfrowania jest niezbędny, umożliwia obliczenie odwrotnego algorytmu (odszyfrowanie)
 - dla MAC jest niepotrzebny
- Kodowanie długości
 - dla szyfrowania jest niepotrzebne, cała wiadomość jest odtwarzana
 - dla MAC nie ma innego sposobu zaznaczenia długości pliku
 - gdyby zwracać wszystkie MAC'i też nie byłoby bezpiecznie
 - są powody, by długość kodować jako pierwszy blok

- Dowolna funkcja $h : [*] \rightarrow [n]$
 - dziedzina: ciągi bitów dowolnej (dużej) długości
 - przeciwdziedzina: ciągi bitów długości ustalonej i niedużej
- Przykład $h : [n + n] \rightarrow [n]$, $h(x, y) = x \oplus y$
 - funkcję tę można iterować i przetwarzać ciągi dowolnej długości:
 $H(x, \langle y, Z \rangle) = H(h(x, y), Z)$
 - dla dowolnego ciągu bitów trzeba jeszcze uzupełnić ostatni niepełny blok
- Własności funkcji H
 - łatwo się oblicza (w przykładzie jest to po prostu suma)
 - łatwo znaleźć dwa ciągi t.ż. $H(x) = H(y)$

Zastosowania funkcji skrótu

- Nie kryptograficzne:
 - znajdowanie indeksów tablic dla argumentów ze zbioru $[*]$ albo zbioru $[N]$ dla dużego N (tablice mieszające)
 - wykrywanie przypadkowych błędów transmisji: przesyłane są wiadomość m oraz skrót $h(m)$, odczytywane są m_1 oraz h_1 , jeśli $h(m_1) \neq h_1$, to znaczy, że wystąpił błąd
- Kryptograficzne:
 - wykrywanie celowych i złośliwych zmian dokumentów
 - skrócenie wiadomości dla kryptografii asymetrycznej (podpis)
- Inne nazwy:
 - *hash*, odcisk palca (*fingerprint*), *message digest*
 - MAC (dla funkcji z hasłem)

Własności kryptograficznych funkcji skrótu


- Dana wiadomość m oraz skrót $h(m)$
 - zmieniona wiadomość m_1 oraz $h(m_1)$
 - jeśli $h(m) = h(m_1)$ to nie ma sposobu wykrycia zmiany
 - w.p.p. atakujący musi przekazać inny skrót
- Założenia:
 - łatwo obliczyć (ale nie MAC, które wymaga hasła)
 - trudno jest znaleźć jakiegokolwiek m_1 t.ż. $h(m_1) = y$ (funkcja jednokierunkowa, problem 1. przeciwwobrazu)
 - trudno jest znaleźć m_1 t.ż. $h(m_1) = h(m)$ dla danego m (słaba bezkolizyjność, problem 2. przeciwwobrazu)
 - trudno jest znaleźć jakiegokolwiek dwie wiadomości m oraz m_1 takie że $h(m) = h(m_1)$ (silna bezkolizyjność)

Atak urodzinowy

- Jakie jest prawdopodobieństwo, że dwie osoby spośród n mają urodziny tego samego dnia?
 - dla $n = 2$, prawd. $\approx \frac{1}{366}$
 - dla $n = 367$, prawd. $= 1$
 - dla $n = 23$, prawd. $> \frac{1}{2}$
- Prawd. $\approx \exp(-n^2/2N)$
 - jest znacznie większe niż żądanie, by zachodziła równość z zadaną wartością
 - dla dwóch zestawów liczb $< N$ o wielkości \sqrt{N} elementów jest duża szansa na wspólny element
 - np. dla $N = 2^{56}$ wystarczy zgromadzić zestawy po 2^{28} elementów, czyli gigabajty

Metoda Merkle-Damgarda

- Dana funkcja $h_s : [n + n] \rightarrow [n]$ (funkcja kompresji)
 - (może zależna od dodatkowego parametru s)
 - iteracja dla ciągów dowolnej długości: $H(x, \langle y, Z \rangle) = H(h_s(x, y), Z)$
 - dla dowolnego ciągu bitów trzeba jeszcze uzupełnić ostatni, niepełny blok ciągu
 - na końcu blok kodujący długość pliku
 - wektor początkowy jest ustalony



Metoda Merkle-Damgarda, własności

- Jeśli funkcja kompresji h_s ma własność bezkolizyjności, to funkcja H też ma taką własność
 - dw. gdyby dwie wiadomości miały ten sam skrót H
 - to albo będą się różnić wielkością (ostatni blok da kontrprzykład dla h_s)
 - albo będą się różnić wcześniej, wcześniejszy blok da kontrprzykład dla h_s
- MAC w algorytmie Merkle-Damgarda
 - NMAC (*nested MAC*): dla klucza k dodatkowy blok na końcu $h_s(k, H(m))$


Standard SHA-1 (*secure hash algorithm*)

- Opracowany przez NIST (National Institute of Standards and Technology)
 - pierwsza wersja była niedoskonała, stąd SHA-1
 - produkuje skrót 160 bitowy
- Standard określa funkcję kompresji, jest ona iterowana
 - $m = \{m_0, m_1, m_2, \dots\}$, X_0 początkowa wartość rejestru, $X_{j+1} = h(X_j, m_j)$, $h(m)$ jest równe ostatniej wartości rejestru
 - standard określa też początkową wartość rejestru oraz sposób wypełnienia ostatniego bloku: ostatnie 64 bity określają długość m , brakujące są uzupełnione zerami

SHA-1 dla jednego bloku

- Operacje nieliniowe: 'and', 'or' bitowo
 - operacje liniowe: 'not', \oplus czyli dodawanie modulo 2, dodawanie modulo 2^{32} , przesunięcie bitów w lewo
 - definicja funkcji pomocniczych
 $f(B, C, D) = (B \wedge C) \vee ((\neg B) \wedge D)$, $f(B, C, D) = B \oplus C \oplus D$, ...
 - definicja 85 stałych 32 bitowych
- Rejestr ma 5 elementów: A, B, C, D, E po 32 bity, inicjalizowanych przez 5 stałych, blok ma 16 fragmentów 32-bitowych
 - dla 80 rund obliczamy $shift_5(A) + f(B, C, D) + E + W + K \mapsto A$,
 $A \mapsto B$, $shift_{30}(B) \mapsto C$, $C \mapsto D$, $D \mapsto E$, f są różne dla różnych rund, K kolejną stałą, w jest początkowo fragmentem bloku, później $W_j = shift(W_{j-3} \oplus W_{j-8} \oplus W_{j-14} \oplus W_{j-16})$

Jedna runda w SHA-1



http://nsfsecurity.pr.erau.ededu/crypto/sha_1.html

cytat za *Cryptography and Network Security: Principles and Practice* William

MD5

- Autor: Rivest
- Skrót 128 bitowy
 - 4 rejestry 32 bitowe
 - 64 rundy (4 cykle po 16)
 - w każdym cyklu inna funkcja nieliniowa z efektem lawinowym, przesunięcia bitów, dodawanie z bieżącymi danymi
- Znaleziono kolizje!
- MD2, inna funkcja
 - bardzo wolna
 - ale chyba bezpieczniejsza
 - jest używana w protokole PEM, bezpiecznej poczty elektronicznej

Inne funkcje skrótu

- Funkcje md4, md5, ripemd, sha-1
- Silna bezkolizyjność jest problematyczna, tylko sha-1 jest w miarę dobre
 - znaleziono dwa certyfikaty X.509 o tej samej wartości funkcji skrótu md5
 - gdyby jeden był podpisany przez wystawcę certyfikatów, to automatycznie drugi też
- Nie ma problemów ze słabą bezkolizyjnością i nieodwracalnością
 - gdyby te własności były naruszone, to duża część kryptografii byłaby w kłopotcie

- Dana funkcja szyfrująca $E : [\ell+n] \rightarrow [n]$, n długość szyfrowanych bloków, ℓ długość klucza
 - można przerobić ją na funkcję skrótu na wiele sposobów:
 $h(k, m) = E(k, m) \oplus m$, albo $E(k, m) \oplus m \oplus k$, albo $E(k, k \oplus m) \oplus m$ albo ...
 - i dalej iterować użycie dla większej liczby bloków
 - jest to równoważne zastosowaniu szyfru symetrycznego w wersji blokowej i przyjęciu ostatniego bloku jako skrótu
- Możliwość ataku urodzinowego wyklucza szyfry o kluczu mniejszym niż np. 128 bitów
 - np. klasyczny DES

- Funkcja skrótu h pozwala wygenerować ciąg pseudolosowy
 - x_0 musi być losowe i przesłane niezależnie jako IV
 - $x_j = 8$ bitów z $h(k, x_{j-1})$, k jest kluczem, jest użyte jako ciąg pseudolosowy
 - tzn. $c_j = m_j \oplus x_j$, ciąg x_j jest dodawany do wiadomości w celu zaszyfrowania/odszyfrowania

Szyfrowanie i uwierzytelnianie

- Dane dwa klucze, jak zapewnić poufność i integralność?
 - 1) przesłać $Enc(k_1, m)$ oraz $MAC(k_2, m)$
- ale MAC może ujawnić całą wiadomość
 - a praktycznie zawsze jest deterministyczny: ŻŁE
 - 2) przesłać $Enc(k_1, m || MAC(k_2, m))$
- szyfr nie musi być odporny na atak z wybranym kryptogramem
 - być może nawet da się odtworzyć cały tekst jawny: ŻŁE

PRAWDIŁOWE ROZWIĄZANIE:

 - 3) przesłać $Enc(k_1, m)$ oraz $MAC(k_2, Enc(k_1, m))$
- uniemożliwia atak przez modyfikację kryptogramu
- bezpieczeństwo takie same jak dla Enc
- UWAGA: MAC i Enc mogą być funkcjami wzajemnie odwrotnymi (szyfry blokowe itp), klucze muszą być różne